

TP2

June 20, 2020

1 TP2 : Interação e Concorrência

- João Bastos (A47419)
- André Sá (A76361)

Cada grupo de estudantes tem um número atribuído e pretendemos utilizar um algoritmo quântico para encontrar o nosso número. O nosso grupo de trabalho é o 1 e usaremos o algoritmo de Grover para o encontrar numa lista de 8 possíveis. Assim, para representação dos números possíveis (0 a 7) teremos 3 qubits ($2^3 = 8$) e pretendemos encontrar a representação binária de 1 (001).

```
[87]: from qiskit import *
      %matplotlib inline
      from qiskit.tools.visualization import *
      import math as m
      import qiskit.tools.jupyter
      from qiskit.tools.monitor import backend_overview, backend_monitor
      from qiskit.compiler import transpile
      from qiskit.providers.aer.noise import NoiseModel
      from qiskit.visualization import plot_circuit_layout
      from qiskit.ignis.mitigation.measurement import (complete_meas_cal,
      ↪ tensored_meas_cal,
      CompleteMeasFitter,
      ↪ TensoredMeasFitter)
```

```
[88]: backend_state = Aer.get_backend("statevector_simulator")
      backend_unitary = Aer.get_backend('unitary_simulator')
      backend = Aer.get_backend("qasm_simulator")
```

```
[89]: def intersperse(iterable, delimiter):
      it = iter(iterable)
      yield next(it)
      for x in it:
          yield delimiter
          yield x

      def concat_circuits(circuits, barrier=None):
          if barrier:
              circuits = intersperse(circuits, barrier)
```

```

ret = QuantumCircuit()
for circuit in circuits:
    ret += circuit
return ret

def run(circuit, backend, **kwargs):
    if type(backend) is str:
        backend = Aer.get_backend(backend)
    return execute(circuit, backend, **kwargs).result()

def bloch_sphere(circuit, result):
    return plot_bloch_multivector(result.get_statevector(circuit))

def state_city(circuit, result):
    return plot_state_city(result.get_statevector(circuit))

def state_hinton(circuit, result):
    return plot_state_hinton(result.get_statevector(circuit))

def state_qsphere(circuit, result):
    return plot_state_qsphere(result.get_statevector(circuit))

def histogram(circuit, result):
    return plot_histogram(result.get_counts(circuit))

```

2 Algoritmo de Grover

2.1 Inicialização

Pretendemos que todos os estados sejam verificados portanto criamos uma sobreposição uniforme de todas as possibilidades aplicando um Hadamard a cada qubit. Sendo $N = 2^3 = 8$,

$$\frac{1}{\sqrt{N}} \sum_{x_i} |x_i\rangle$$

```

[90]: n = 3 # n° de bits
      N = 2 ** n

      cr = ClassicalRegister(n, 'c')
      qr = QuantumRegister(n, 'q')


      barrier = QuantumCircuit(qr, cr)
      barrier.barrier()

      init = QuantumCircuit(qr, cr)

```


```
init.h(qr)
init.draw('mpl')
```

[90]:



```
[5]: result = run(init, backend_state)
      bloch_sphere(init, result)
```

[5]:



Como podemos verificar, cada qubit está no estado de sobreposição $|+\rangle$ tendo igual probabilidade de ocorrer $|0\rangle$ como $|1\rangle$. Assim, todos os resultados têm igual probabilidade de ocorrer como podemos verificar na matriz seguinte.

```
[6]: result.get_statevector().real
```

```
[6]: array([0.35355339, 0.35355339, 0.35355339, 0.35355339, 0.35355339,
          0.35355339, 0.35355339, 0.35355339])
```

2.2 Oráculo

Pretendemos assinalar o nosso número de grupo mudando a fase da componente $|001\rangle$. Para tal optámos por um oráculo de fase que evita usar um qubit auxiliar diminuindo os erros na execução.

O oráculo de fase consiste em seleccionar a componente pretendida ($|001\rangle$), aplicar um CCZ e reverter a seleção aplicada anteriormente.

Uma vez que o operador CCZ não existe em qiskit decompusemo-lo em $(I \otimes I \otimes H) \cdot CNOT \cdot (I \otimes I \otimes H)$.


$$-\alpha_{001}|001\rangle + \beta \sum_{x_i \neq 001} |x_i\rangle$$

```
[7]: def ccZ(circuit, c1, c2, t):
      circuit.h(t)
      circuit.ccx(c1, c2, t)
      circuit.h(t)

      def phase_oracle(circuit, qr):
          circuit.x(qr[0])
          circuit.x(qr[1])
          ccZ(circuit, qr[0], qr[1], qr[2])
          circuit.x(qr[0])
          circuit.x(qr[1])
```


```
[8]: oracle = QuantumCircuit(qr, cr)
      phase_oracle(oracle, qr)
      oracle.draw('mpl')
```

```
[8]:
```



```
[9]: circuit = concat_circuits([ init, oracle ], barrier=barrier)
circuit.draw('mpl')
```

[9]:




```
[10]: result = run(circuit, backend_state)
result.get_statevector(circuit).real
```

```
[10]: array([ 0.35355339,  0.35355339,  0.35355339,  0.35355339, -0.35355339,
            0.35355339,  0.35355339,  0.35355339])
```


```
[11]: state_city(circuit, result)
```

```
[11]:
```



```
[12]: state_hinton(circuit, result)
```

```
[12]:
```



Como se pode verificar a componente $|100\rangle$ (que representa o $|001\rangle$ pretendido) manteve a amplitude mas alterou a fase, tal como pretendíamos.

2.3 Amplificação

Apesar da mudança de fase, neste momento mantemos as probabilidades iguais para todos casos, o que não nos ajuda muito para o que pretendemos. O objetivo desta secção é aumentar a probabilidade de obtermos o resultado pretendido. Para isso, invertamos e aumentamos a amplitude da componente pretendida em torno da

média das amplitudes (A) e simultaneamente reduzimos a amplitude das restantes componentes de forma uniforme.


$$(2A + \alpha_{001})|001\rangle + (2A - \beta) \sum_{x_i \neq 001} |x_i\rangle$$

```
[13]: def diffuser(circuit, qr):
        circuit.h(qr)
        circuit.x(qr)
        ccZ(circuit, qr[0], qr[1], qr[2])
        circuit.x(qr)
        circuit.h(qr)
```

```
[14]: amplifier = QuantumCircuit(qr, cr)
        diffuser(amplifier, qr)


        amplifier.draw('mpl')
```

[14]:





```
[15]: circuit = concat_circuits([ init, oracle, amplifier ], barrier=barrier)
        circuit.draw('mpl')
```

[15]:



```
[16]: result = run(circuit, backend_state)
state_city(circuit, result)
```

[16]:



Verificamos que a magnitude da componente $|001\rangle$ foi aumentada.

2.4 Medição


A medição é a projeção do estado quântico de cada um dos qubits para um bit clássico. Ao ser medido, cada qubit colapsa para um dos estados possíveis, não sendo mais possível obter o estado quântico inicial.

Apresentamos de seguida o circuito com as 4 secções referidas separadas por barreiras:

```
[17]: measurements = QuantumCircuit(qr, cr)
measurements.measure(qr, cr)

circuit = concat_circuits([ init, oracle, amplifier, measurements ],
↪barrier=barrier)
circuit.draw('mpl')
```

[17]:



2.4.1 O iterador de Grover

Antes de fazermos as medições podemos melhorar a probabilidade de medirmos o valor pretendido. Para isso, iremos repetir o iterador de Grover que consiste em aplicar o oráculo e a amplificação. Lov Grover definiu que o número ideal de iterações é aproximadamente $\frac{\pi}{4}\sqrt{N}$, algo que podemos verificar de seguida.


```
[18]: times = round((m.pi/4) * m.sqrt(N))
      times
```

[18]: 2

2.4.2 Uma iteração


```
[19]: circuit_1it = concat_circuits([ init ] + ([ oracle, amplifier ] * 1) + [
      ↪measurements ])
      circuit.draw('mpl')
```

[19]:



```
[20]: result = run(circuit_1it, backend)
      fst_loop_counts = result.get_counts(circuit_1it)
      plot_histogram(fst_loop_counts)
```


[20]:



2.4.3 Duas iterações


```
[21]: circuit_2it = concat_circuits([ init ] + ([ oracle, amplifier ] * 2) + [
    ↪measurements ])
circuit.draw('mpl')
```

[21]:



```
[22]: result = run(circuit_2it, backend)
snd_loop_counts = result.get_counts(circuit_2it)
plot_histogram(snd_loop_counts)
```


[22]:



2.4.4 Três iterações


```
[23]: circuit_3it = concat_circuits([ init ] + ([ oracle, amplifier ] * 3) + [
    ↪measurements ])
circuit.draw('mpl')
```

[23]:



```
[24]: result = run(circuit_3it, backend)
trd_loop_counts = result.get_counts(circuit_3it)
plot_histogram(trd_loop_counts)
```


[24]:



2.4.5 Análise de resultados

```
[25]: plot_histogram([ fst_loop_counts, snd_loop_counts, trd_loop_counts ], legend=[  
    ↪ "1 Iteration", "2 Iterations", "3 Iterations" ], figsize=(18, 10))
```

[25]:



Como se pode verificar, houve um aumento significativo entre aplicar uma e duas iterações, no entanto ao aplicar uma terceira há uma diminuição substancial.

3 Simulação de ruído

```
[27]: provider = IBMQ.load_account()  
provider.backends(simulator=False, open_pulse=False)
```

```
[27]: [<IBMQBackend('ibmqx2') from IBMQ(hub='ibm-q', group='open', project='main')>,  
<IBMQBackend('ibmq_16_melbourne') from IBMQ(hub='ibm-q', group='open',  
project='main')>,  
<IBMQBackend('ibmq_vigo') from IBMQ(hub='ibm-q', group='open',  
project='main')>,  
<IBMQBackend('ibmq_ourense') from IBMQ(hub='ibm-q', group='open',  
project='main')>,  
<IBMQBackend('ibmq_london') from IBMQ(hub='ibm-q', group='open',  
project='main')>,  
<IBMQBackend('ibmq_burlington') from IBMQ(hub='ibm-q', group='open',  
project='main')>,  
<IBMQBackend('ibmq_essex') from IBMQ(hub='ibm-q', group='open',  
project='main')>,  
<IBMQBackend('ibmq_rome') from IBMQ(hub='ibm-q', group='open',  
project='main')>]
```

```
[105]: %qiskit_backend_overview
```

```
VBox(children=(HTML(value="<h2 style ='color:#ffffff; background-color:#000000;padding-top: 1%
```

Tendo em conta o valor elevado do T1 e T2 - que se refere à média do tempo de vida dos qubits até chegar à decoerência - à reduzida taxa de erros de medida e cx, e ainda ao facto de ter uma boa disponibilidade optámos pelo device backend `ibmq_vigo`.

```
[91]: my_provider_ibmq = IBMQ.get_provider(hub='ibm-q', group='open', project='main')  
backend_device = my_provider_ibmq.get_backend('ibmq_vigo')  
backend_device
```

```
VBox(children=(HTML(value="<h1 style='color:#ffffff;background-color:#000000;padding-top: 1%;p
```

```
[91]: <IBMQBackend('ibmq_vigo') from IBMQ(hub='ibm-q', group='open', project='main')>
```

```
[34]: coupling_map = backend_device.configuration().coupling_map  
noise_model = NoiseModel.from_backend(backend_device)
```

```
basis_gates = noise_model.basis_gates


print(basis_gates)
```

```
['cx', 'id', 'u2', 'u3']
```

```
[37]: result_noise = run(circuit_2it,
                        backend,
                        noise_model=noise_model,
                        coupling_map=coupling_map,
                        basis_gates=basis_gates)


counts_noise = result_noise.get_counts(circuit_2it)
plot_histogram(counts_noise)
```

[37]:



```
[38]: plot_histogram([snd_loop_counts, counts_noise], legend=[ "Simulação",
↪ "Simulação com ruído" ], figsize=(18, 10))
```

[38]:



Podemos ver que os erros produzidos pelo ruído no backend device serão significativos, pelo que devemos otimizar o circuito de forma a reduzir a taxa de erro.

4 Optimização do circuito

Após simulação com ruído do backend device seleccionado vamos executar no mesmo para podermos fazer uma análise mais correcta do ganho efectivo na optimização.

```
[41]: shots=1024

#executar o circuito na máquina real
#job_G_r = execute(circuit_2it, backend_device, shots=shots)

#jobID_G_r = job_G_r.job_id()

print('JOB ID: {}'.format(jobID_G_r))
```

JOB ID: 5eee298334af18001bf1e7b9

```
[94]: %qiskit_job_watcher ## widget para visualizar o estado da job
      %%qiskit_disable_job_watcher ## para fechar o widget
```


Accordion(children=(VBox(layout=Layout(max_width='710px', min_width='710px')),), layout=Layout

<IPython.core.display.Javascript object>

```
[44]: # Recolha de resultados do job executado no backend device
job_get=backend_device.retrieve_job("5eee298334af18001bf1e7b9")


result_G = job_get.result()
counts_G = result_G.get_counts(circuit_2it)
```

```
[45]: plot_histogram([snd_loop_counts, counts_noise, counts_G], legend=[ "Simulação_
↳sem ruído", "Simulação com ruído", "Execução em dispositivo real"],_
↳figsize=(18, 10))
```




```
[70]: circuit_real = transpile(circuit_2it, backend=backend_device)
circuit_real.draw(output='mpl', scale=0.5)
```

[70]:



```
[71]: circuit_opt = transpile(circuit_2it, backend=backend_device,
    ↪optimization_level=3)
circuit_opt.draw(output='mpl', scale=0.5)
```

[71]:




```
[73]: circuit_opt.depth()
```

```
[73]: 71
```

```
[54]: plot_circuit_layout(circuit_opt, backend_device)
```

```
[54]:
```



Após ser aplicada uma otimização de nível 3 à tradução do circuito para a backend device notamos uma ligeira melhoria quanto à profundidade do circuito.

4.1 Otimização do número de gates

Na tentativa de diminuição do número de erros testamos a diminuição do número de gates no circuito fazendo a substituição de algumas combinações de gates por outras.

```
[74]: cr = ClassicalRegister(n, 'c')
      qr = QuantumRegister(n, 'q')

      qc_short = QuantumCircuit(qr, cr)

      qc_short.h([ qr[0], qr[1] ])
      qc_short.x([ qr[0], qr[1] ])

      #####

      qc_short.ccx(qr[0], qr[1], qr[2])
      qc_short.x([ qr[0], qr[1] ])
      qc_short.h([ qr[0], qr[1] ])
      qc_short.x([ qr[0], qr[1] ])
```

```

if False:
    qc_short.h(qr[2])
    qc_short.z(qr[2])
else:
    qc_short.x(qr[2])
    qc_short.h(qr[2])

#####

qc_short.ccx(qr[0], qr[1], qr[2])
qc_short.x([ qr[0], qr[1] ])
qc_short.h([ qr[0], qr[1] ])
qc_short.x([ qr[0], qr[1] ])

if False:
    qc_short.z(qr[2])
    qc_short.h(qr[2])
else:
    qc_short.h(qr[2])
    qc_short.x(qr[2])

#####

qc_short.ccx(qr[0], qr[1], qr[2])
qc_short.x([ qr[0], qr[1] ])
qc_short.h([ qr[0], qr[1] ])
qc_short.x([ qr[0], qr[1] ])

if False:
    qc_short.h(qr[2])
    qc_short.z(qr[2])
else:
    qc_short.x(qr[2])
    qc_short.h(qr[2])

#####


qc_short.ccx(qr[0], qr[1], qr[2])
qc_short.x([ qr[0], qr[1] ])
qc_short.h([ qr[0], qr[1] ])
qc_short.z(qr[2])

qc_short.measure(qr, cr)

qc_short.draw('mpl')


```

[74]:




```
[75]: result = run(qc_short, backend)
      histogram(qc_short, result)
```

[75]:



```
[77]: qc_short_real = transpile(qc_short, backend=backend_device)
      qc_short_opt = transpile(qc_short, backend=backend_device, optimization_level=3)
      circuit_opt.draw(output='mpl', scale=0.5)
```

[77]:



```
[78]: qc_short_real.depth()
```

```
[78]: 76
```

```
[79]: qc_short_opt.depth()
```

```
[79]: 64
```

```
[80]: # execução do circuito com otimização nível 3 #
      #job_G_r2 = execute(circuit_opt, backend_device, shots=shots)

      #jobID_G_r2 = job_G_r2.job_id()

      #print('JOB ID: {}'.format(jobID_G_r2))
```

JOB ID: 5eee32dc34af18001bf1e844

```
[83]: job_get2=backend_device.retrieve_job("5eee32dc34af18001bf1e844")
```

```
result_G2 = job_get2.result()
counts_G2 = result_G2.get_counts(circuit_opt)
```

```
[81]: # execução do circuito com otimização nível 3 + otimização n° de gates #
#job_G_r3 = execute(qc_short_opt, backend_device, shots=shots)

#jobID_G_r3 = job_G_r3.job_id()

#print('JOB ID: {}'.format(jobID_G_r3))
```


JOB ID: 5eee32e06bb14a001cca1b2e

```
[84]: job_get3=backend_device.retrieve_job("5eee32e06bb14a001cca1b2e")
```

```
result_G3 = job_get3.result()
counts_G3 = result_G3.get_counts(qc_short_opt)
```

```
[86]: plot_histogram([counts_G, counts_G2, counts_G3], legend=[ "Sem otimização",
↳ "Otimização nível 3", "Otimização nível 3 + gates"], figsize=(18, 10))
```

[86]:



Apesar da profundidade do circuito com otimização do número de gates ter diminuído, contrainstintivamente teve um pior resultado que o circuito com apenas a otimização nível 3. Assim, teremos de abdicar desta última otimização.

5 Mitigação de erros com o Ignis

Por fim, após termos executado o nosso circuito vamos usar o Ignis para, sobre os resultados obtidos, mitigar os erros de medição do backend device escolhido.

Primeiro geramos a matriz de calibração a partir das propriedades do backend device.

```
[107]: meas_calibs, state_labels = complete_meas_cal(qubit_list=[0,1,2], qr=qr,   
↪        circlabel='mcal')
```

```
[93]: #job_ignis = execute(meas_calibs, backend=backend_device, shots=shots)

#jobID_run_ignis = job_ignis.job_id()

#print('JOB ID: {}'.format(jobID_run_ignis))
```


JOB ID: 5eee477b61ad6a00190bd14f

```
[95]: job_get=backend_device.retrieve_job("5eee477b61ad6a00190bd14f")

cal_results = job_get.result()
```

```
[96]: meas_fitter = CompleteMeasFitter(cal_results, state_labels, circlabel='mcal')

meas_fitter.plot_calibration()
```



```
[106]: print("Fidelidade média de Medição: %f" % meas_fitter.readout_fidelity())
```

Fidelidade média de Medição: 0.934570


Podemos verificar que a fidelidade média de medição é bastante elevada pelo que a melhoria não deverá ser significativa.

Por fim, aplicamos a calibração aos resultados com um filtro baseado na matriz de calibração.

```
[100]: meas_filter = meas_fitter.filter

# Resultados com mitigação
mitigated_results = meas_filter.apply(result_G2)
mitigated_counts = mitigated_results.get_counts()
```

```
[102]: plot_histogram([snd_loop_counts, counts_G, counts_G2, mitigated_counts],
    ↪ legend=[ "Ideal", "Sem optimização", "Optimização nível 3", "Optimização_
    ↪ nível 3 com mitigação de erros"], figsize=(18, 10))
```



Verificamos uma melhoria após a mitigação dos erros de medição no entanto os resultados ficam muito aquém do ideal.

Referências:

- [Complete 3-Qubit Grover Search on a Programmable Quantum Computer](#)
- [Qiskit Documentation](#)